Comparison and Final Report

Naive Bayes and Maxent evaulation metrics results:

Maxent:

شاه) = test data precision(0.9859154929577465 | امام) = test data precision(0.9859154929577465

شاه) = test data recall(0.9761904761904762 | امام) test data recall(0.9722222222222222

شاه) = test data F1(0.9534883720930233 = امام) test data F1(0.979020979020979 امام)

test data accuracy = 0.9652173913043478 total test data precision = 0.955 total test data recall = 0.974 total test data f1-score = 0.9632

Naive Bayes:

Precision: 0.9043414036956803 Recall: 0.9147347826086956 f1-score: 0.9201540006087957 accuracy: 0.9304347826086956 according to the results you can see that Maxent had a better performance and results rather than NaiveBayes

Naive Bayes

I calculated number of true_positives, true_negatives, false_positives and false negatives. Actually I have a dictionary like {'tp': 0, 'tn': 0, 'fp': 0, 'fn': 0} for both of my labels and iterate through my data and calculate it. According to the following formula we can calculate the metrics:

- precision = (tp) / (tp + fp)
- recall = (tp) / (tp + fn)
- f1-score = 2*(precision * recall) / (precision + recall)
- accuracy = (tp + tn) / (tp + tn + fp + fn)

If a prediction is true then we add one to its tp and other label's tn and the same way for other states .. Example of one sentence estimated wrong in naive bayes:

امام اصلاحات ارضی آقا به اینجا منتهی شد که یک بازاری درست کرد برایآمریکا که آمریکا چیزهایی که باید بریزد دور به ایران بفروشد نفت ما را که دارند این طور می برند بعد از سی سال دیگر)به قول شاه (بعد از سی سال دیگر تمام می شود نفت نه اینکه نفت تمام می شود نخیر تمام دارند می کننددارند با این لوله های بزرگ که به اندازه این اطاق شاید بعضی هایشانبزرگی اش باشد به اندازه قامت انسان زیادتر بلندیش دورش هست هیکلش هست دارند با زور نفت های ما را در می آورند و می فرستند طرف امریکا عوضش هم که باید به ما بدهند عوضش هم دورش هست هیکلش هست دارند با زور نفت های ما را در می آورند و می فرستند طرف امریکا عوضش هم که باید به ما بدهند عوضش هم اسلحه ای را که می خواهد امریکا بیایداهران پایگاه داشته باشد در مقابل شوروی باید یک چیزی هم به ایران بدهداگر چنانچه اجازه اش نباید اجازه بدهند باید یک چیزی هم بدهد به ما که بیاید پایگاه درست بکند نفت ما را می گیرد اجازه بدهند باید یک چیزی هم بدهد به ما که بیاید پایگاه درست برگ حتی از ممالک دیگر پایگاه درست می کند برای خودش عوض به ما می هوض یعنی پایگاه درست کردن برای آمریکا یا آن اسلحه های بزرگ حتی از ممالک دیگر فرانسه می خرند آن چیزهای بسیار گران قیمت را که به درد ما نمی خورد به عوضش نفت را دارند می برند طیاره های 350میلیون دلاری میلیون فرانسه می خرند آن چیزهای بسیار گران قیمت را که به درد ما نمی خورد به عوضش نفت را دارند می برند طیاره های 350میلیون دلاری میلیون

Here our classifier detected this as امام which is actually امام. The reason is because of Naive Bayes pays attention to bag-of-words and the order and sequence of words is not important to it. And most of the times Shah talked about financial stuffs so it learned that each of these words are more probable in مام rather than امام. But we should notice that we need a model which can recognize a group of words and it should be like a sequence and not only a unigram but more than that.

Maxent

I defined some features in Maxent: At first compilation I had these features:

- 1. Length
- 2. has_arabic
- 3. unigram(each word of class)

1- It indicates length of sentence because most of the times I saw that Imam Khomeini's speech and usual sentences is much more longer than Shah! 2- I saw that Imam Khomeini uses much more Arabic words rather than Shah. 3- All of us know that each word is a good data to be used as a feature. (except stop words) Then I trained my Maxent modelusing these features Example of model1 sentences given to maxent trainer:

امام خيانتكار:3 و:1 ما:1 اين:1 سلطنت:2 نمى:1 خواهيم:1 اصلش:1 از:1اول:1 بوده:1 خوب:1 هايشان:1 هم:1 بد:1 بودند:1 آنهايى:1 كه:1 شما:1 يا:1

I evaluated this model metrics and I decided to make it better

Before Optimization Results: (model1)

Then I decides to add bigrams to my feature because I undrestood that the 5 percent problem is almost problem of sequence of words and it cames from this that unigrams are not enough!

So I added bigrams t my fetures and it became like this:(model2) 1:مام همین:1 طور:1 صاف:1 زیرا:1 شاید:1 مستودع:1 باشد:1 الله:1 الله:1 الله:1 الله:1 مستودع:1 مستودع:

Then I trained it and I Reached some better results:)) After Optimization Results: (model2)

As you can see I could reach accuracy of 96.52 percent which is better than model1.

Question of Documnet: So generally i compared these two methods above. (feature having or not having differences and such those things) Totally I observed that Maxent had a better functionality than Naive Bayes But I can't generalize that if a classifier is much more complicated it's better... I can say that if there are much more logical features covered it can have a better complexity And Also we have a bad effect in Naive Bayes which Maxent doesn't have that (Bag-Of-Words Effect) But we also should be careful about over fitting. We should try not to focus on some special features and in that way the model overfits ..